

- 系统模型

- 联邦学习

给定需要解决的问题的相对精度 ϵ 和本地迭代的相对精度阈值 θ 情况下的全局迭代次数上界

$$I^g(\epsilon, \theta) = \frac{\zeta \cdot \log\left(\frac{1}{\epsilon}\right)}{1 - \theta}$$

client 获得本地相对精度 θ_k 的本地迭代上界

$$I_k^l(\theta_k) = \gamma_k \log\left(\frac{1}{\theta_k}\right)$$

在给定各个 θ_k 的情况下全局迭代次数

$$I^g(\epsilon, \theta) = \frac{\zeta \cdot \log\left(\frac{1}{\epsilon}\right)}{1 - \max \theta_k}$$

- 费用模型

- communication cost

$$T(\theta_k) = \frac{T_k}{1 - \theta_k}$$

泰勒展开近似为

$$T(\theta_k) = T_k(1 + \theta_k)$$

- computing cost

即 $I_k^l(\theta_k)(1 + \theta_k)$

综合两种费用，得到

$$C_k(\theta_k) = (1 + \theta_k) \cdot (v_k \cdot T_k + (1 - v_k) \cdot \gamma_k \log\left(\frac{1}{\theta_k}\right))$$

- 激励机制

主从博弈 (Stackelberg Game)：非同时进行，后手知道先手的策略，先手知道后手知道先手的策略.....双方的策略是共同知识

- Client(后手)

一开始 MEC server 会告诉 client 一个统一的收益率

价值函数： $v_k(\theta_k) = 1 - \theta_k$

client 的效用函数为

$$u_k(r, \theta_k) = r(1 - \theta_k) - C_k(\theta_k), \forall k \in \mathcal{K}$$

因为 $u''_{22} < 0$, $u_k(r, \theta_k)$ 关于 θ_k 严格凹，有唯一的极大值点 $\theta_k^*(r)$

- MEC Server(先手)

令 $x(\epsilon)$ 为达到相对精确度 ϵ 的迭代次数

$$x(\epsilon) = \zeta \cdot \log \left(\frac{1}{\epsilon} \right)$$

给全局迭代次数设一个上界 δ , 有

$$I^g(\epsilon, \theta) = \frac{x(\epsilon)}{1 - \theta} \leq \delta$$

MEC Server 的效用函数为

$$\mathcal{U}(x(\epsilon), r | \theta^*) = \beta(1 - 10^{-(ax(\epsilon)+b)}) - r \sum_{k \in \mathcal{K}} (1 - \theta_k^*(r))$$

◦ 引理1 (KKT 条件)

最优化情况下 $x^*(\epsilon) = \delta(1 - \max_k \theta_k^*(r))$

◦ Stackelberg Equilibrium

$$\begin{aligned} \mathcal{U}(r^*, \theta^*) &\geq \mathcal{U}(r, \theta^*) \\ u_k(\theta_k^*, r^*) &\geq u_k(\theta_k, r^*) \end{aligned}$$

■ 后手的最优策略

$$\begin{aligned} u'_k(r, \theta_k) &= 0 \\ \log \left(e^{\frac{1}{\theta_k(r)}} \theta_k(r) \right) &= \left[\frac{r + v_k T_k}{(1 - v_k) \gamma_k} - 1 \right] = g_k(r) \end{aligned}$$

最优的 $\hat{\theta}_k$ 在满足 $g_k(r) = \log \left(e^{\frac{1}{\hat{\theta}_k(r)}} \hat{\theta}_k(r) \right)$ 的时候取到

$$\theta_k^*(k) = \min\{\hat{\theta}_k, \theta_{th}\}$$

■ 先手的最优策略

考虑筛选 client 的策略

$$z_k = \begin{cases} 1 & \text{if } r > \hat{r}_k \\ 0 & \text{otherwise} \end{cases}$$

其中

$$\hat{r}_k = g_k^{-1}(\log(e^{\frac{1}{\theta_{th}}} \theta_{th}))$$

即能让 client k 本地相对精度达到阈值 θ_{th} 的最小激励值

所以先手需要最大化效用函数

$$\max \beta(1 - 10^{-(ax^*(\epsilon)+b)}) - r \sum_{k \in \mathcal{K}} z_k \cdot (1 - \theta_k^*(r))$$

使用如下算法

Algorithm 1 MEC Server's Utility Maximization

- 1: Sort clients as with $\hat{r}_1 < \hat{r}_2 < \dots < \hat{r}_K$
- 2: $\mathcal{R} = \{\}, \mathcal{A} = \mathcal{K}, j = K$
- 3: **while** $j > 0$ **do**
- 4: Obtain the solutions r_j to the problem

$$\max_{r \geq \hat{r}_1} \beta \left(1 - 10^{-(ax^*(\epsilon)+b)} \right) - r \sum_{k \in \mathcal{A}} (1 - \theta_k^*(r)).$$

- 5: **if** $r_j > \hat{r}_j$, **then** $\mathcal{R} = \mathcal{R} \cup \{r_j\}$;
 - 6: **end if**
 - 7: $\mathcal{A} = \mathcal{A} \setminus j$;
 - 8: $j = j - 1$;
 - 9: **end while**
 - 10: Return $r_j \in \mathcal{R}$ with the highest optimal values in the problem (4)
-

最终得到的 $\{r^*, \theta^*\}$ 就是 Stackelberg 均衡点